

# МЕТОДЫ ОПТИМИЗАЦИИ

## Семинар 8. Линейная регрессия (продолжение)

### Несколько примеров линейной регрессии

#### Фиттинг поверхности в пространстве

Пример линейной регрессии - полиномиальный фиттинг двумерных данных

Задача следующая, имеются данные  $\vec{Y}, \vec{X}_1, \vec{X}_2$  - вектор-столбцы наблюдений некоторых параметров

В первом варианте предполагается, что  $\vec{Y}$  зависит от  $\vec{X}_1$  и  $\vec{X}_2$  линейно, то есть каждую координату вектора  $\vec{Y}$  можно выразить в виде линейной комбинации соответствующих координат векторов  $\vec{X}_1$  и  $\vec{X}_2$  :

$$Y_i = \beta_1 + \beta_2 X_{1i} + \beta_3 X_{2i} \text{ (i - индекс строки)}$$

$$\vec{Y} = [\vec{1}, \vec{X}_1, \vec{X}_2] \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

Во втором варианте предполагается, что зависимость квадратичная:

$$Y_i = w_1 + w_2 X_{1i} + w_3 X_{2i} + w_4 X_{1i}^2 + w_5 X_{2i}^2$$


$$\vec{Y} = [\vec{1}, \vec{X}_1, \vec{X}_2, \vec{X}_1^2, \vec{X}_2^2] \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{bmatrix}$$

Данные взяты из книжки:

```
% данные из "https://raw.githubusercontent.com/probml/probml-data/main/data/moteData/moteData.mat"
% пример из книжки К.Р.Мурфи "Probabilistic machine learning. An introduction"
data = load(fullfile(get_folder(), "DataSurfFit.mat"))
```

```
data = struct with fields:
  y: [53x1 double]
  X: [53x2 double]
```

```
Y = data.y;
X1 = data.X(:,1);
X2 = data.X(:,2);
N = numel(X1);
scatter3(X1,X2,Y)
```



Решаем задачу линейно регрессии для двух вариантов зависимости

```
I1 = ones([N 1]);
V1 = [I1,data.X];% матрица полинома первой степени (три колонки)
W1 = lsqminnorm(V1,Y) % аппроксимируем линейной зависимостью
```

```
W1 = 3×1
    16.4141
     0.0137
     0.0037
```

```
norm1 = norm(Y - V1*W1)
```

```
norm1 = 5.8802
```

```
% W1 = V1\Y ;
V2 = [I1,data.X,data.X.^2]; % матрица для полинома второй степени (пять колонок)
W2 = lsqminnorm(V2,Y) % аппроксимируем квадратичной зависимостью
```

```
W2 = 5×1
    14.4583
     0.1972
     0.1736
    -0.0045
    -0.0052
```

```
norm2 = norm(Y - V2*W2)
```


```
norm2 = 3.2956
```

```
% W2 = V2\Y ; % аппроксимируем квадратичной зависимостью
% Функция lsqminnorm решает задачу Ax=b в смысле наименьших квадратов
% Отличие функции x = lsqminnorm(A,b) от x = A\b в том, что она минимизирует не
% только норму квадратичного отклонения, но и (это актуально если матрица A является
% сингулярной) норму самого вектора
```


```
% теперь построим поверхность по результатам интерполяции
M = 10
```

```
M = 10
```

```
xrange = linspace(min(X1), max(X1), M);
yrange = linspace(min(X1), max(X2), M);
% оборачиваем расчет полинома в указатель на функцию (функция будет
% вызываться скалярно в цикле)
z_fun_linear = @(x,y,w) w(1)+ x*w(2) + y*w(3);
z_fun_square = @(x,y,w) z_fun_linear(x,y,w) +w(4)*x^2 + w(5)*y^2;
[Xgrid,Ygrid] = meshgrid(xrange,yrange);
Z1 = zeros(M);
Z2 = zeros(M);
for ii = 1:M
    for jj = 1:M
        x = Xgrid(ii,jj);y = Ygrid(ii,jj);
        Z1(ii,jj) = z_fun_linear(x,y,W1);
        Z2(ii,jj) = z_fun_square(x,y,W2);
    end
end
ax = get_next_ax();
surf(ax,Xgrid,Ygrid,Z1)
hold(ax,"on")
scatter3(ax,X1,X2,Y,"or")
hold(ax,"off")
```



```
ax = get_next_ax();  
surf(Xgrid,Ygrid,Z2)  
hold(ax,"on")  
scatter3(ax,X1,X2,Y,"or")  
hold(ax,"off")
```



% Двойной вложенный цикл это постыдно, упражнение:  
% сгенерить данные для поверхности без использования циклов

## Пример 2. Линейная регрессия нелинейной задачи.

Иногда нелинейную задачу можно свести к линейной путем некоторого нелинейного преобразования, для примера рассмотрим следующую задачу:

Есть данные  $\vec{y}$  и  $\vec{x}$ , предполагается, что  $y(x) = \alpha_1 x^{\alpha_2} \exp(-\frac{\alpha_3}{x})$ , нужно найти параметры  $\alpha_1, \alpha_2, \alpha_3$

Данная задача сводится к задаче линейной регрессии (несмотря на то, что в изначальной постановке параметры входят нелинейно, если прологарифмировать обе части, то:

$$\ln(y) = \ln(\alpha_1) + \alpha_2 * \ln(x) - \alpha_3 \frac{1}{x}$$

Если ввести новые переменные, то получи мзадачу линейной регрессии :

$$\vec{Y} = \ln(\vec{y}) \quad \vec{X}_1 = \ln(\vec{x}) \quad \text{и} \quad \vec{X}_2 = 1/\vec{x}$$

$$\beta_1 = \ln(\alpha_1), \quad \beta_2 = \alpha_2, \quad \beta_3 = -\alpha_3$$

$$\vec{Y} = [\vec{1}, \vec{X_1}, \vec{X_2}] \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$


```
clearvars
e = 0.2;
N = 62;
x = linspace(0.3,6,N)';
a = [20 -2 2.2];
y = a(1)*(x.^a(2)).*exp(-a(3)./x) + e*randn(N,1);
X1 = log(x);
X2 = 1./x;
I = ones([N,1]);
X = [I,X1,X2];
Y = log(y);
b = lsqminnorm(X,Y);
a_fitted = [exp(b(1)) b(2) -b(3)]
```

```
a_fitted = 1×3
    19.5557    -2.0433     2.1180
```

```
a_real=a
```

```
a_real = 1×3
    20.0000    -2.0000     2.2000
```

```
ax= get_next_ax();
scatter(ax,x,y);hold(ax,"on")
plot(ax,x,exp(X*b));hold(ax,"off");legend(ax,["Initial" "Fit"])
```



Вопрос что при всех этих нелинейных преобразованиях происходит с ошибкой....

## Погрешность линейной регрессии

### Введение. Понятия из статистики. Описательная статистика

У нас есть случайная переменная, которая может принимать некоторый (дискретный) набор возможных значений:

$$\nu \sim \nu_1 \dots \nu_N$$

Вероятность переменной иметь некоторое определенное значение из этого дискретного набора характеризуется набором вероятностей:

$$P \sim p_1 \dots p_N, \sum p_i = 1$$

Для некоторой случайной переменной, которая берется из некоторого распределения  $P$ , математическое ожидание будет:

$$\hat{\nu} = \mathbb{E}[\nu \sim P] = \sum p_i \nu_i \quad - \text{ } i \text{ - индексы возможных исходов! (их всего } N \text{ штук)}$$

Среднее значение результатов набора из  $M$  испытаний:

$$\mu_\nu = \frac{\sum_{j=1}^M \nu_j}{M} \quad - \text{ применяется для экспериментальной оценки мат. ожидания по } M \text{ испытаниям}$$

(j - перебирает испытания, испытаний было M штук)

Разброс некоторой переменной характеризуется вариацией:

$$\mathbb{V}[\nu] = \mathbb{E}[(\nu - \hat{\nu})^2] = \sum_i p_i (\nu_i - \hat{\nu})^2 = \mathbb{E}[(\nu^2)] - (\mathbb{E}[\nu])^2,$$

Для экспериментальной оценки вариации по выборке из M испытаний:

$$S_{\nu\nu} = \frac{\sum_{j=1}^M (\nu_j - \hat{\nu})^2}{M - 1}$$


$std(x) = \sqrt{S_{\nu\nu}}$  - стандартное отклонение

Ковариация двух случайных переменных:

$$Cov(\nu, \eta) = \mathbb{E}[(\nu - \mathbb{E}[\nu])(\eta - \mathbb{E}[\eta])] = \sum_{ij} p_{ij} (\nu_i - n)(\eta_i - m),$$

$$Cov(\nu, \nu) = \mathbb{V}(\nu),$$

```
clearvars
M = 100; % число испытаний
N = 9; % число цифр (число возможных исходов)
possible_values = transpose(1:1:N); % сами цифры все возможные значения
a = randi(N,M,1); % случайно выбирает значения в диапазоне от 1 до N, M раз
histogram(get_next_ax(),a,[1.5;possible_values(2:end) + diff(possible_values)/2])
```



```
tb = table();
tb.Average = mean(a); % считаем среднее значение (оценка математического ожидания)
```



```

p_i = 1/N; % вероятность выбрать конкретную цифру
p = p_i*ones(N,1);% вектор вероятностей для всех цифр
tb.Expectation = p'*possible_values;
tb.STD2 = std(a)^2;
tb.Variation = p'*((possible_values-tb.Expectation).^2);
tb

```

tb = 1×4 table

	Average	Expectation	STD2	Variation
1	4.8300	5	6.8698	6.6667

Коэффициент корреляции двух случайных величин:

$$Cor(\eta, \nu) = \frac{Cov(\eta, \nu)}{\sqrt{V(\eta)} \sqrt{V(\nu)}}$$

Если у нас есть вектор-столбец измерений некоторой случайной величины  $x$ , то есть, каждая из координат этого вектора - образцы (сэмплы, розыгрыши) случайной величины  $x$ , экспериментальной оценкой вариации будет:

$$S_{xx} = (\vec{X} - \mu_x \vec{I})^T (\vec{X} - \mu_x \vec{I}) / (N - 1), \quad \vec{I} - \text{вектор состоящий из единиц,}$$

$$\mu_x = \frac{\sum_{i=1}^N (x_i)}{N} = \frac{\vec{I}^T \vec{X}}{N} - \text{экспериментальная оценка математического ожидания.}$$

Ковариации линейно комбинации двух случайных величин:

$$Cov(a\nu + b\eta) = a^2 Cov(\nu, \nu) + 2ab Cov(\nu, \eta) + b^2 Cov(\eta, \eta) = a^2 V(\nu) + 2ab Cov(\nu, \eta) + b^2 V(\eta)$$

Если у нас есть вектор случайных величин (то есть, вектор, координаты которого случайные величины, каждая получена из своего распределения, каждая имеет свое среднее и свою вариацию :

$$\vec{\beta} = [\beta_1, \dots, \beta_i, \dots, \beta_N]^T$$

Среднее значение этого вектора - тоже вектор, каждая из координат которого - это среднее значение соответствующей случайной величины:

$$\mathbb{E}[\vec{\beta}] = [\mathbb{E}[\beta_1], \dots, \mathbb{E}[\beta_i], \dots, \mathbb{E}[\beta_N]]$$

То можно ввести матрицу ковариации размером  $N \times N$  этого вектора, элемент  $i$ -й строки  $j$ -го столбца которой:

$$K_{\beta ij} = Cov(\vec{\beta})_{ij} = Cov(\beta_i, \beta_j)$$

На диагонали матрицы ковариации стоят, соответственно вариации.

Таким образом, матрица ковариации вектора случайных величин :

$$K_{\beta} = \mathbb{E}[(\vec{\beta} - \mathbb{E}[\vec{\beta}])(\vec{\beta} - \mathbb{E}[\vec{\beta}])^T]$$

%вспомним что такое внешнее произведение:

```
clearvars
```

```
a = sym("a",[2,1],"real")
```

a =

$$\begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

a\*a'

ans =

$$\begin{pmatrix} a_1^2 & a_1 a_2 \\ a_1 a_2 & a_2^2 \end{pmatrix}$$

Экспериментальная оценка матрицы ковариации:

Если у нас есть матрица измерений размером  $N \times M$ :

$X = [\vec{X}_1^T, \dots, \vec{X}_i^T, \dots, \vec{X}_N^T]^T$ , в которой каждый столбец - это вектор сэмплов  $N$  случайных величин

Каждая  $i$ -я строка матрицы  $X$ - это  $M$  сэмплов случайной величины  $x_i$  - компоненты случайного вектора

$\vec{x}$

Для экспериментальной оценки матрицы ковариации:

$$K_X = [X - \vec{\mu} \vec{1}_M^T][X - \vec{\mu} \vec{1}_M^T]^T / M$$

$\vec{\mu}$  - вектор-столбец размером  $N \times 1$  средних значений каждой из строк

$$\vec{\mu} = \frac{X \vec{1}_M}{M}$$

```
clearvars
```

```
M = 3;
```

```
N=2;
```

```
a = sym("a",[1 M],"real"); % вектор сэмплов случайно величины a
```

```
b = sym("b",[1 M],"real"); % вектор сэмплов случайной величины b
```

```
X = [a;b] % матрица измерений
```

x =

$$\begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \end{pmatrix}$$

```
Im = sym(ones(M,1))
```

Im =

$$\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

```
mu = X*Im/M
```

mu =

$$\begin{pmatrix} \frac{a_1}{3} + \frac{a_2}{3} + \frac{a_3}{3} \\ \frac{b_1}{3} + \frac{b_2}{3} + \frac{b_3}{3} \end{pmatrix}$$

```
mus = sym("mu",[N 1],"real")
```

mus =

$$\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

```
Mu = mus*Im'
```

Mu =

$$\begin{pmatrix} \mu_1 & \mu_1 & \mu_1 \\ \mu_2 & \mu_2 & \mu_2 \end{pmatrix}$$

```
Kx = (X-Mu)*(X-Mu)'
```

Kx =

$$\begin{pmatrix} (a_1 - \mu_1)^2 + (a_2 - \mu_1)^2 + (a_3 - \mu_1)^2 & \sigma_1 \\ \sigma_1 & (b_1 - \mu_2)^2 + (b_2 - \mu_2)^2 + (b_3 - \mu_2)^2 \end{pmatrix}$$

where

$$\sigma_1 = (a_1 - \mu_1) (b_1 - \mu_2) + (a_2 - \mu_1) (b_2 - \mu_2) + (a_3 - \mu_1) (b_3 - \mu_2)$$

```
disp("Вариация случайной переменной x :")
```

Вариация случайной переменной x :

```
disp(Kx(1,1));
```

$$(a_1 - \mu_1)^2 + (a_2 - \mu_1)^2 + (a_3 - \mu_1)^2$$

```
Kx(1,2)
```

$$\text{ans} = (a_1 - \mu_1) (b_1 - \mu_2) + (a_2 - \mu_1) (b_2 - \mu_2) + (a_3 - \mu_1) (b_3 - \mu_2)$$

```
clearvars
```

```
x1 = randn([1 100]);
x2 = 1*x1 + randn([1 100]);
mu = [mean(x1);mean(x2)];
X = [x1-mu(1);x2-mu(2)];
X*X'/(99)
```

```
ans = 2x2
    0.9409    0.8817
    0.8817    1.8302
```

```
cov(X')
```

```
ans = 2x2
    0.9409    0.8817
    0.8817    1.8302
```

## Распределения

Теперь плотность вероятности - не дискретная величина, а непрерывная, которая дается функцией

$$p(x; \mu, \sigma, \dots)$$

$x$  – переменная, а то, что стоит после запятой - параметры распределения,

Иногда бывает условное распределение вероятности (сегодня в явном виде не будет), то есть, например, распределение вероятности  $x$ , при заданном  $y$  (тоже случайном, но фиксированном), записывают:

$$p(x|y; \mu, \sigma, \dots)$$

Кумулятивная вероятность - вероятность случайной переменной иметь значением меньше  $x$

$$P(x|t < x) = \int_{-\infty}^x p(t)dt$$

Понятно, что  $\int_{-\infty}^{+\infty} p(t)dt = 1$

Основные элементы описательной статистики:

$$\mathbb{E}[x] = \int_{-\infty}^{+\infty} xp(x)dx \text{ (еще это называют первым моментом)}$$

$$\mathbb{V}[x] = \int_{-\infty}^{+\infty} (x - \mathbb{E}[x])^2 p(x)dx = \int_{-\infty}^{+\infty} x^2 p(x)dx - (\mathbb{E}[x])^2$$

Значок  $x \sim P(x)$  обозначает, что случайная переменная  $x$  берется из распределения  $P(x)$ . То есть это аналог вызова генератора случайных чисел, например, запись  $x=rand()$  в матлаб эквивалентна  $x \sim P(x)$ , где  $P(x)$  - равномерное распределение от -1 до 1.

Запись:


$$\zeta \sim \mathcal{N}(\mu, \sigma^2)$$

Обозначает что случайная переменная  $\zeta$  получена из нормального распределения с параметрами  $\mu$  и  $\sigma$ .

Формула для нормального распределения:

$$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

```
clearvars
% строим нормальное распределение
mu=0; % первый параметр распределения
sig = 5.76; % второй параметр распределения
x = linspace(-10,10,100)';
distr_fun = norm_distribution_function(mu,sig);
plot(get_next_ax(),x,distr_fun(x))
```



Вероятность того, что переменная имеет значение меньше заданного (кумулятивное распределение вероятности):


$$P(x|t < x) = \int_{-\infty}^x p(t)dt = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

Вероятность того, что случайная переменная распределенная нормально лежит в интервале от  $x_1$  до  $x_2$ :

$$P(x \in [x_1, x_2]) = P(x_2) - P(x_1) = \int_{x_1}^{x_2} \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \left[ \int_{-\infty}^{x_2} - \int_{-\infty}^{x_1} \right] \mathcal{N}(x; \mu, \sigma) dx$$

Код ниже рассчитывает вероятность того, что случайная величина  $x$  распределенная нормально лежит в интервале  $-\sigma \leq x \leq \sigma$

```
clearvars
x = linspace(-10,10,100)';
sig = 3.18;
distr_fun = norm_distribution_function(0,sig);
sigma_multiplier=1;
P = integral(distr_fun,-sigma_multiplier*sig,sigma_multiplier*sig);
% integral - функция численного интегрирования
ax = get_next_ax();
area(ax,x,distr_fun(x),"FaceAlpha",0.2)
hold(ax,"on");
sub_x = x((x>=-sigma_multiplier*sig)&(x<=sigma_multiplier*sig));
area(sub_x,distr_fun(sub_x),"FaceAlpha",0.2);
title(ax,"P(-"+string(sigma_multiplier) + "*\sigma"+ "\leq x\leq "+string(sigma_multiplier) + "*\sigma)=" + string(P))
ylabel(ax," N(\mu,\sigma)")
xlabel(ax,"Значение x")
hold(ax,"off");
```



$erf(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$  - интеграл от гауссиана - специальная функция

$$P(x|t < x) = \frac{1}{2} [1 - erf(-\frac{x}{\sqrt{2}})]$$

```
% ЭТО СООТВЕТСТВЕННО ТОЧНОЕ ЗНАЧЕНИЕ
tb = table(P,erf(sigma_multiplier/sqrt(2)));
tb.Properties.VariableNames = ["Численное интегрирование" "Точное значение"];
tb
```

```
tb = 1x2 table
```

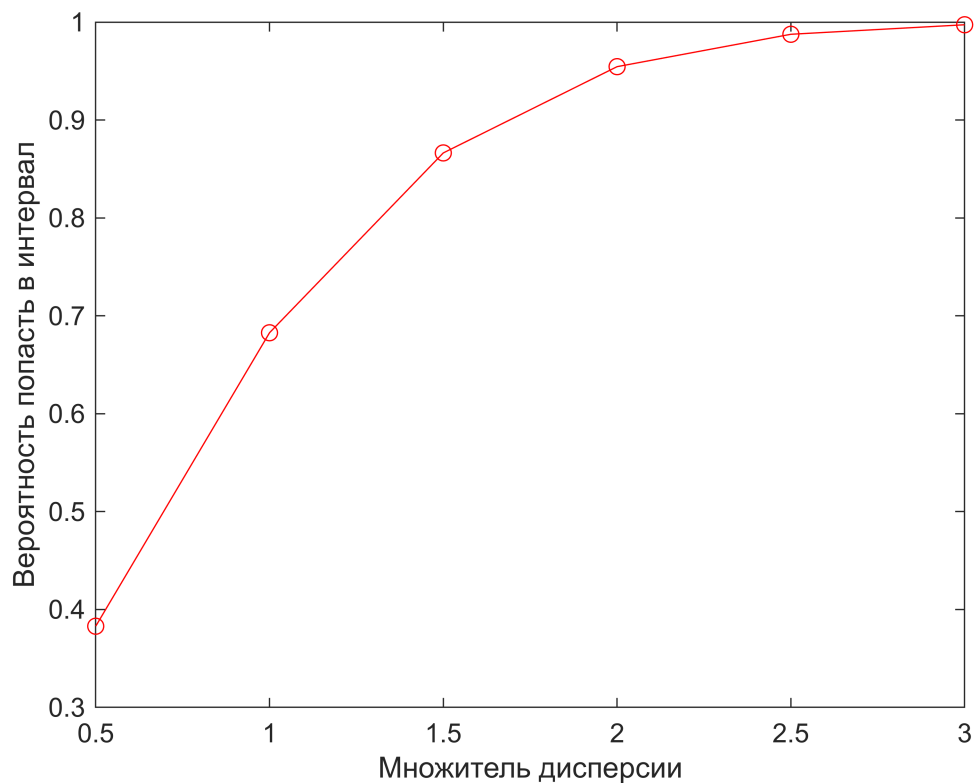
	Численное интегрирование	Точное значение
1	0.6827	0.6827

```
clearvars
% СТРОИМ НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ
sig = 1;
mu = 0;
distr_fun = norm_distribution_function(mu,sig);
sigma_multiplier = 0.5:0.5:3;
P = zeros(numel(sigma_multiplier),1);
tic
%parfor ii = 1:numel(sigma_multiplier)
for ii = 1:numel(sigma_multiplier)
    m = sigma_multiplier(ii);
    % ИНТЕГРИРУЕМ ЧИСЛЕННО ОТ MU-M*SIG ДО MU + M*SIG
    P(ii) = integral(distr_fun,mu-m*sig,mu+m*sig);
end
toc
```

Elapsed time is 0.035474 seconds.

```
ax = get_next_ax();

plot(ax,sigma_multiplier,P,"or-");
xlabel(ax,"Множитель дисперсии");
ylabel(ax,"Вероятность попасть в интервал")
```



```
table(sigma_multiplier(:),P,VariableNames = ["Множитель", "Вероятность"])
```

```
ans = 6x2 table
```

	Множитель	Вероятность
1	0.5000	0.3829
2	1	0.6827
3	1.5000	0.8664
4	2	0.9545
5	2.5000	0.9876
6	3	0.9973

$\mathcal{N}(0, 1)$  - стандартное нормальное распределение (функция randn)

Чтобы получить переменную, взятую из  $\zeta \sim \mathcal{N}(\mu, \sigma^2)$  из переменной, взятой из стандартного распределения  $\eta \sim \mathcal{N}(0, 1)$

$$\zeta \sim \mathcal{N}(\mu, \sigma^2) = \mu + \sigma^2 \mathcal{N}(0, 1)$$

Важное распределение - хи квадрат. Хи-квадрат распределение показывает распределение значений суммы квадратов нормальных случайных переменных:




$$\chi_k^2 = \sum_{i=1}^k Z_i^2$$

где  $Z_i \sim \mathcal{N}(0, 1)$

Важное распределение - распределение Вейбулла (прочность хрупких материалов подчиняется статистике Вейбулла)

$$p_{weib}(x|a, b) = \frac{b}{a} \left(\frac{x}{a}\right)^{b-a} e^{-(x/a)^b} \text{ для } x \geq 0$$

```
%В statistics and machine learning toolbox есть функция fitdist,  
% которая позволяет подбирать распределение под данные  
data = load(fullfile(get_folder(),"DataWeibDistr.mat"));  
X = data.MAT;  
scatter(get_next_ax(),1:numel(X),X)
```



```
fitdist(X,"Weibull")
```

```
ans =  
WeibullDistribution  
  
Weibull distribution  
A = 249.174 [244.015, 254.443]  
B = 13.0011 [10.7242, 15.7614]
```

```
% distributionFitter - приложения для фитинга распределений
```



```
clearvars
% картинки разных распределений
% наша задача - построить распределения на основе "экспериментальных" данных

M = 50; % число точек сетки
tmin=-5;tmax=286;t = transpose(linspace(tmin,tmax,M));
distrib = 'Normal'; % выбираем тип генератора случайных чисел
mu=122.37; % первый параметр распределения
sigma = 6.98; % второй параметр распределения
N = 1e4; % число экспериментов
pd = make_dist(distrib,mu=mu,sig=sigma); %генерит генератор случайных чисел
```

```

% для различных двухпараметрических распределений(обертка для встроенных
генераторов, для всех кроме
% нормального и равномерного распределения нужен statistical toolbox
g = pd(N);% возвращает вектор из N чисел, распределенных в соответствии с данным
распределением
distr = zeros(M-1,1);
for ii = 1:M-1
    distr(ii) = sum((g<t(ii+1))&(g>=t(ii)))/N; % считаем число точек, которые
попали в интервал
end
sum_distr = sum(distr)

```

```
sum_distr = 0.9961
```

```
average_g = mean(g) % оценка среднего из среднего арифметического
```

```
average_g = 122.5214
```


```
var_g = (g - average_g)'*(g - average_g)/(N-1) % оценка вариации
```

```
var_g = 2.3164e+03
```

```

ax= get_next_ax();
histogram(ax,g,t)
title(ax,distrib)

```



```

tb = table();
tb.mu = mu;tb.mean = average_g;tb.sig = sigma^2;tb.std = sqrt(var_g);

```

tb

tb = 1×4 table

	mu	mean	sig	std
1	122.3700	122.5214	48.7204	48.1291

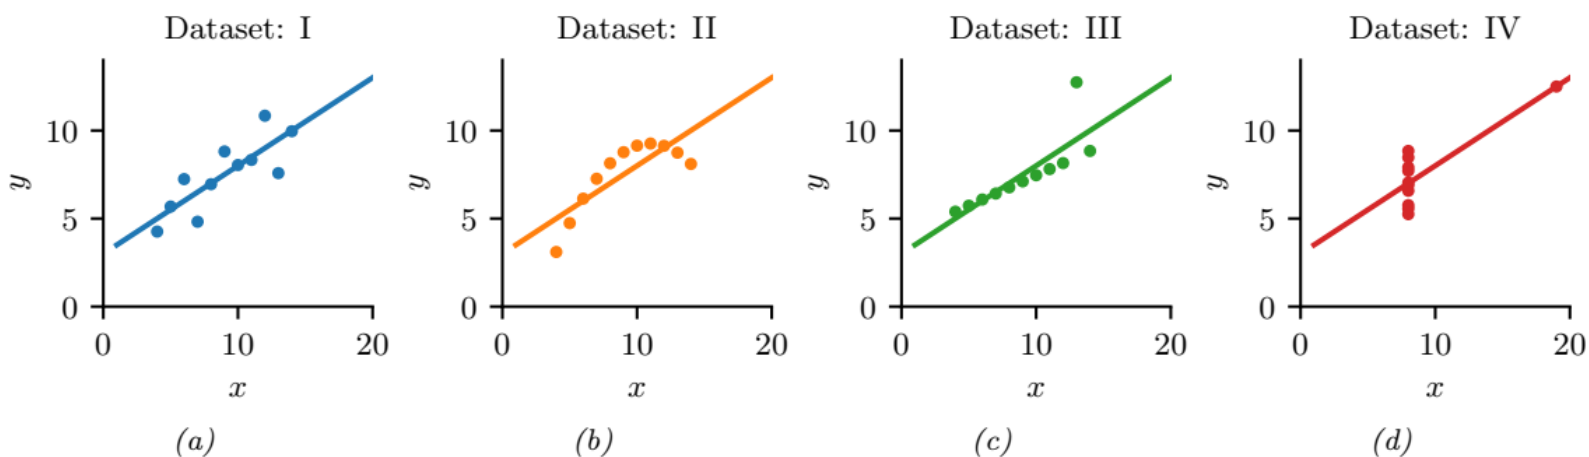


Figure 2.5: Illustration of Anscombe's quartet. All of these datasets have the same low order summary statistics. Generated by [anscombes\\_quartet.ipynb](#).

(картинка из книжки K.P.Murphy "Probabilistic machine learning. An introduction", иллюстрирующая недостаточность дескриптивной статистики, все эти наборы данных имеют одно среднее по каждому из столбцов, вариацию и коэффициент корреляции между  $x$  и  $y$ )

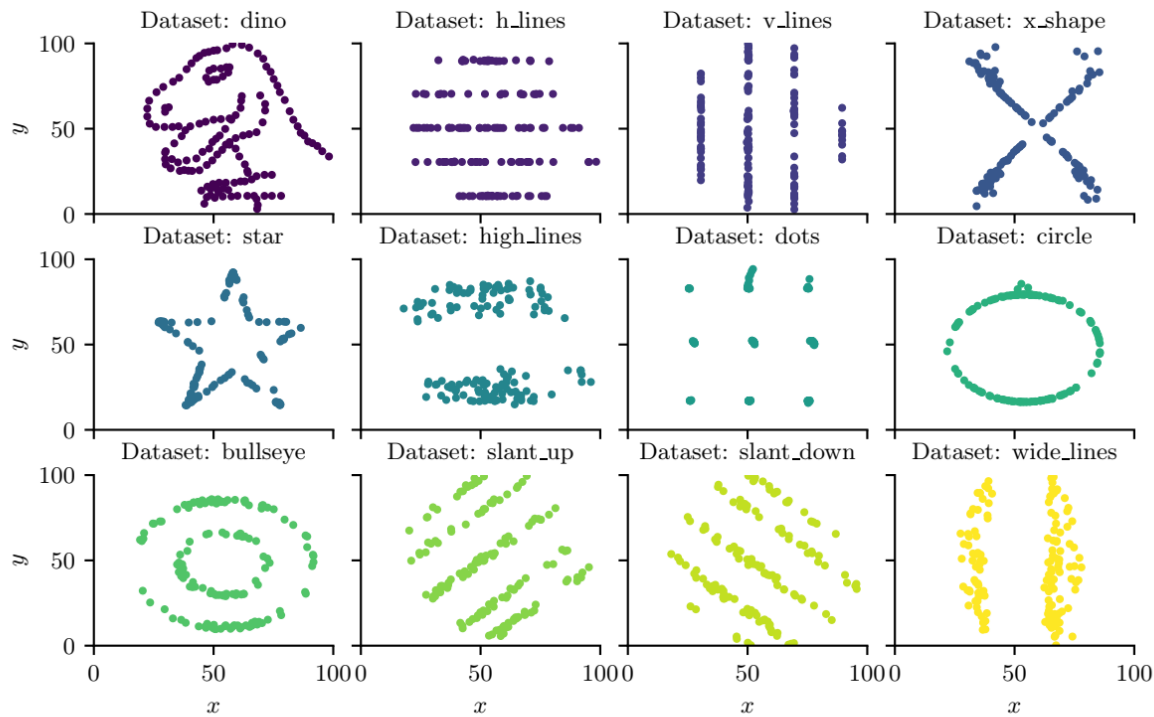


Figure 2.6: Illustration of the Datasaurus Dozen. All of these datasets have the same low order summary statistics. Adapted from Figure 1 of [MF17]. Generated by [datasaurus\\_dozen.ipynb](#).

## Выводы по семинару 8

1. Рассмотрены два примера линейной регрессии, первый - фиттинг данных поверхностью параболоида, второй - сведение нелинейной функции к линейной путем нелинейного преобразования
2. Основные характеристики случайной величины  $\psi$  математическое ожидание  $\mathbb{E}[\psi]$  и вариация  $\mathbb{V}[\psi] = \mathbb{E}[(\psi - \mathbb{E}[\psi])^2]$ , для их оценки по выборке применяется среднее арифметическое и среднее квадратическое отклонение среднего
3. В качестве меры совместного изменения двух случайных величин применяется ковариация  $\text{Cov}(\nu, \eta) = \mathbb{E}[(\nu - \mathbb{E}[\nu])(\eta - \mathbb{E}[\eta])]$
4. Для вектора случайных величин вводят матрицу вариации - ковариации, в которой каждый элемент  $i$ -й строки  $j$ -го столбца соответствует ковариации его  $i$ -й и  $j$ -й координаты
5. Если имеются измерения  $X = [\overset{\rightarrow T}{X_1}, \dots, \overset{\rightarrow T}{X_i}, \dots, \overset{\rightarrow T}{X_N}]^T$ , в которой каждый столбец - это вектор сэмплов  $N$  случайных величин. Каждая  $i$ -я строка матрицы  $X$  - это  $M$  сэмплов случайной величины

$x_i$  - компоненты случайного вектора  $\overset{\rightarrow}{x}$ . Для экспериментальной оценки матрицы ковариации:

$K_X = [X - \overset{\rightarrow}{\mu} I_M][X - \overset{\rightarrow}{\mu} I_M]^T / (M - 1)$ ;  $\overset{\rightarrow}{\mu}$  - вектор-столбец размером  $N \times 1$  средних значений каждой из

строк  $\overset{\rightarrow}{\mu} = \frac{\overset{\rightarrow}{X} I_M}{M}$ .

## ЛИТЕРАТУРА

1. N.Draper, H.Smith . Applied regression analysis. Third edition. Wiley Series in Probability and Statistics.
3. K.Murphy. Probabilistic machine learning. An Introduction. [Book](#)
2. Gilbert Strang - Introduction to Linear Algebra (2016, Wellesley-Cambridge Press)

```
function rus_name = rus(type)
    possible_types = ["stand" "legA" "trig" "legP" "custom"];
    possible_rus_names = ["Стандартный базис" "Присоединенные полиномы Лежандра"
"Тригонометрический базис" "Полиномы лежандра" "Кастомный"];
    flag = possible_types==type;
    if any(flag)
        rus_name = possible_rus_names(flag);
    else
        rus_name = type;
    end

end

function f = norm_distribution_function(mu,sig)
% возвращает анонимную функцию для нормального распределения
    f =@(x) exp(-(x-mu).^2./(2*sig^2))./(sig*sqrt(2*pi));
end

function [V,s] = vandermatrix(t,P,type,polyprod_function)
arguments
    t double
    P (1,1) double {mustBeInteger,mustBePositive} = 2
    type (1,1) string {mustBeMember(type,["stand" "legA" "trig" "legP" "custom"])}
= "stand"
    polyprod_function =[]
end
% создаем матрицу Вандермонда
% type - тип полинома (стандартный базис, полиномы лежандра,
% тригонометрические полиномы)
    t = t(:);
    N = numel(t);
    V = zeros(N,P);
    if ~(type=="custom")
        [Pfun,s] = producing_function(type,t); % возвращаем производящую функцию
для колонки матрицы вандермонда
    else
        assert(~isempty(polyprod_function)||
~isa(polyprod_function,"function_handle"),"Если выбрана кастомная производящая
функция, то нужно ее предоставить")
        s = normalize(t);
        Pfun = @(i)polyprod_function(i,s.x);
    end
    for jj = P:-1:1
```

```

        V(:,jj) = Pfun(jj);
    end
end
function dist= make_dist(type,options)
% возвращает генератор N случайных чисел, распределенных в соответствии
% с двух параметрическими распределениями: нормальным, дельта-равномерным,
% Вейбулла и Хи-квадрат
arguments
    type (1,1) string {mustBeMember(type,["Normal" "Uniform" "Weibull" "Chi2"])}
    options.mu (1,1) =0
    options.sig (1,1)=0
end
mu=options.mu;
sig2=options.sig^2;
switch type
    case "Normal"
        dist = @(N) mu + sig2*randn([N 1]);
    case "Uniform"
        dist = @(N) sqrt(sig2)*(rand([N 1]) -0.5)+ mu;
    case "Weibull"
        dist = @(N) wblrnd(mu,sqrt(sig2),N,1);
    case "Chi2"
        dist = @(N) (mu + sig2*randn([N 1]).^2);
end

end
function norm_struct = normalize2(t)
% функция возвращает стурктуру, в которой хранятся данные для нормировки
if ~issorted(t)
    t = sort(t,"ascend");
end
tmin = t(1);
tmax = t(end);
x = 2.0*((t - tmin) / (tmax - tmin))- 1;
norm_struct = struct("tmin",tmin,"tmax",tmax,"x",x); %t,(max(t) - min(t))
end
function t = denormalize2(s)
    t = 0.5*(s.x + 1.0)*(s.tmax - s.tmin) + s.tmin;
end
function Pn = leg_polyA(i,t) % производящая функция для присоединенных полиномов
Лежандра
persistent P
persistent tleg
leg_type = 'norm';
if isempty(tleg)||isempty(P)||(~isequal(t,tleg))
    P = transpose(legendre(i-1,t,leg_type)); % встроенная функция по сути
возвращает уже матрицу Вандермонда
    tleg = t;
end
if i<=size(P,2)

```

```

        Pn = P(:,i);
        return
    end
    P = transpose(legendre(i,t,leg_type));
    tleg = t;
    Pn = P(:,end);
end
function Pn = trig_poly(i,t) % производящая функция для тригонометрических полиномов
    if i==1
        Pn = ones(size(t));
        return
    end
    if mod(i,2)==0
        Pn = cos(i*t*pi);
    else
        Pn = sin(i*t*pi);
    end
end
function [P,s] = producing_function(type,t)
% функция возвращает производящую функцию для полинома
    s = normalize2(t);
    switch type
        case "stand" % стандартный базис полинома
            P = @(i) s.x.^(i-1);
        case "legA" % присоединенные полиномы Лежандра
            P = @(i) leg_polyA(i,s.x);
        case "legP" % полиномы Лежандра
            P = @(i) legendreP(i-1,s.x) ; % стандартная функция для полиномов лежандра
        case "trig" % тригонометрический базис
            P = @(i) trig_poly(i,s.x);

    end

end

function [new_ax,fig_handle] = get_next_ax(index, axes_name_value_pairs)
% функция, которая возвращает новые оси на новой фигуре (нужна чтобы
% кртинки в ливскрипте нормально строились)
    arguments
        index = []
        axes_name_value_pairs cell = {}
    end
    persistent N;
    if isempty(index)
        if isempty(N)
            N=1;
        else
            N = N+1;
        end
        fig_handle = figure(N);
        clf(fig_handle);

```



```

    new_ax = axes(fig_handle,axes_name_value_pairs{:});
    %disp("fig"+ N)
else
    fig_handle = figure(index);
    clf(fig_handle);
    new_ax = axes(fig_handle,axes_name_value_pairs{:});
end
end
function ax = get_named_ax(title_string)
    ax = get_next_ax();
    title(title_string);
end
function ax = draw_vector(ax,ttl, names,type,varargin)
% функция строит двух- и трех-мерные вектора, а также рассеянные данные из
% матрицы
% ax - оси (если пустые, то создаются новые)
% ttl - заголовок картинки
% names - имена векторов
% type:
%     "vector" - аргументы, которые передаются после интерпретируются
%               как отдельные вектора
%     "point"  - в этом случае передается матрица в качестве аргумента и
%               столбцы матрицы строятся при помощи функций scatter и scatter3 d
%               в зависимости от размерности массива
arguments
    ax =[]
    ttl string =strings(0,1)
    names string =strings(0,1)
    type string {mustBeMember(type,["vector" "point"])}="vector"
end
arguments (Repeating)
    varargin double
end
was_empty = isempty(ax); % это признак того, что все строится на новых осях
if was_empty
    ax = get_next_ax();
else
    hold(ax,"on");
    % if ~isempty(ax.Legend)
    %     leg_before = ax.Legend.String;
    % else
    %     leg_before = strings(0,1);
    % end
end

if strcmp(type,"vector")
    is_3D = numel(varargin{1})==3;
    if is_3D
        [x,y,z] = make_xy(varargin{1});
        plot3(ax,x,y,z,'LineWidth',2,'Marker','o');
    end
end

```

```

        hold on
        for iii = 2:numel(varargin)
            [x,y,z] = make_xy(varargin{iii});
            plot3(ax,x,y,z,'LineWidth',2,'Marker','o');
        end
        grid on
        hold off
    else
        [x,y] = make_xy(varargin{1});
        plot(ax,x,y,'LineWidth',2,'Marker','o');
        hold on
        for iii = 2:numel(varargin)
            [x,y] = make_xy(varargin{iii});
            plot(ax,x,y,'LineWidth',2,'Marker','o');
        end
        grid on
        hold off
    end
    if isempty(names) || (numel(names)~=numel(varargin))
        legend(ax,string(1:numel(varargin)));
    else
        % if ~was_empty
        %     names= [names(:);leg_before(:)];
        % end
        legend(ax,names);
    end
    xlim(ax,[-1 1]);
    ylim(ax,[-1 1]);
    if ~isempty(ttl)
        title(ax,ttl);
    end
else
    %data_number = numel(varargin); % число массивов данных
    is_3D = numel(varargin)==3;
    data = varargin{1};
    if size(data,2)>1
        data = transpose(data);
        is_transpose = true;
    else
        is_transpose = false;
    end
    if ~is_transpose
        for iii = 2:numel(varargin)
            data = [data,varargin{iii}];
        end
    else
        for iii = 2:numel(varargin)
            data = [data,transpose(varargin{iii})];
        end
    end
end

```

```

end

if is_3D
    scatter3(ax,data(:,1),data(:,2),data(:,3));
else
    scatter(ax,data(:,1),data(:,2));
end

end

if ~was_empty
    hold(ax,"off");
end

end

function [x,y,z] = make_xy(col)
% добавляет к координатам вектора нули так, чтобы при помощи функции plot
% строилась линия
switch numel(col)
    case 1
        x = [col(1)];
        y = 0;
        z = 0;
    case 2
        x = [0 col(1)];
        y = [0 col(2)];
        z = zeros(1,2);
    case 3
        x = [0 col(1)];
        y = [0 col(2)];
        z = [0 col(3)];
end

end

function folder = get_folder()
% текущая папка
folder = fileparts(matlab.desktop.editor.getActiveFilename());
end

```